LAB 3

Data Preprocessing in Weka

ให้นักศึกษาทำตามขั้นตอนดังต่อไปนี้

1. ให้ download ไฟล์ดาต้าเซททุกอัน เก็บไว้ที่เครื่อง
2. เปิดโปรแกรม WEKA ขึ้นมา กด Explorer
3. กดปุ่ม Open file แล้วเลือก bank-data.arff จะปรากฏ ดังรูป

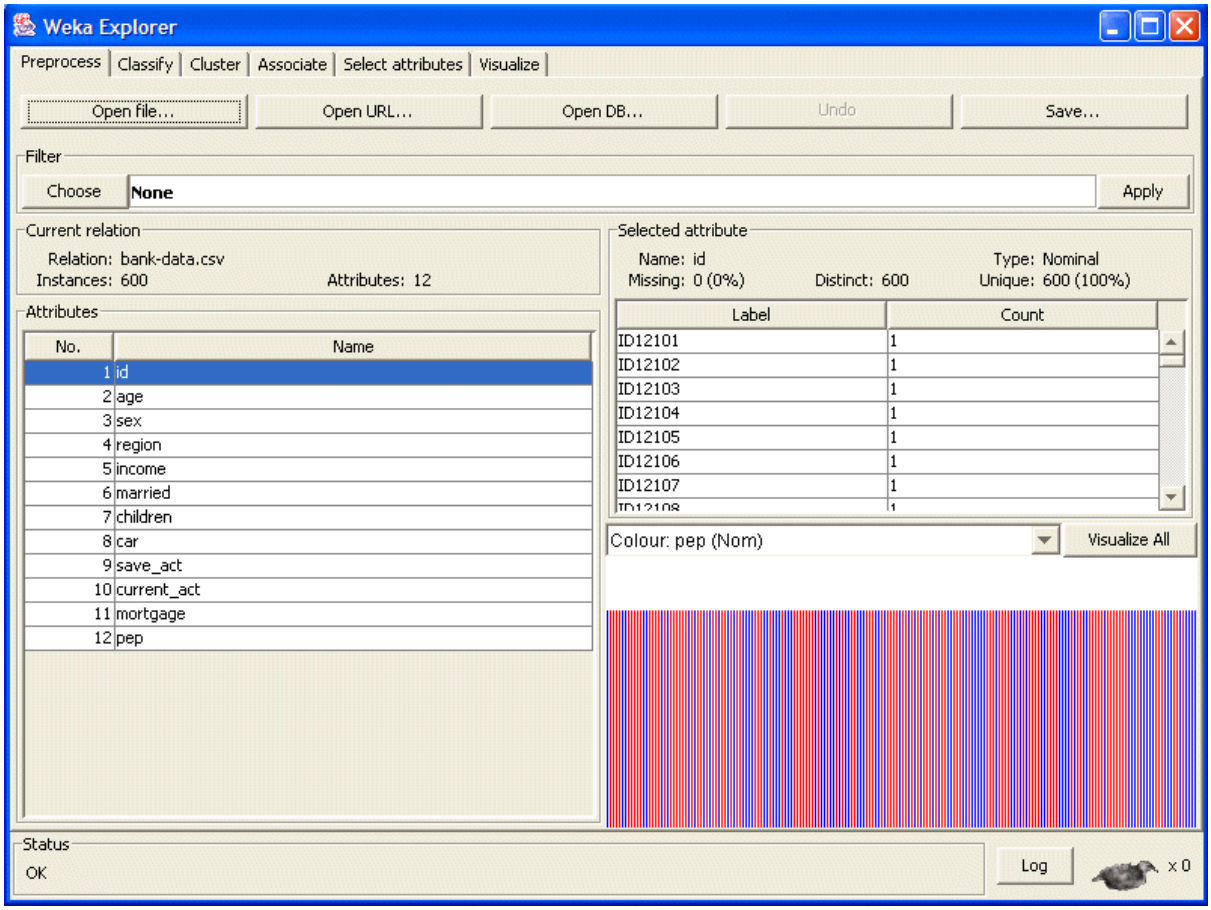

4. ให้เลื่อนคลิกดู Attribute ของ age (อายุ) ให้สังเกตุด้านขวามือในการแสดงค่าของอายุ ดังรูป

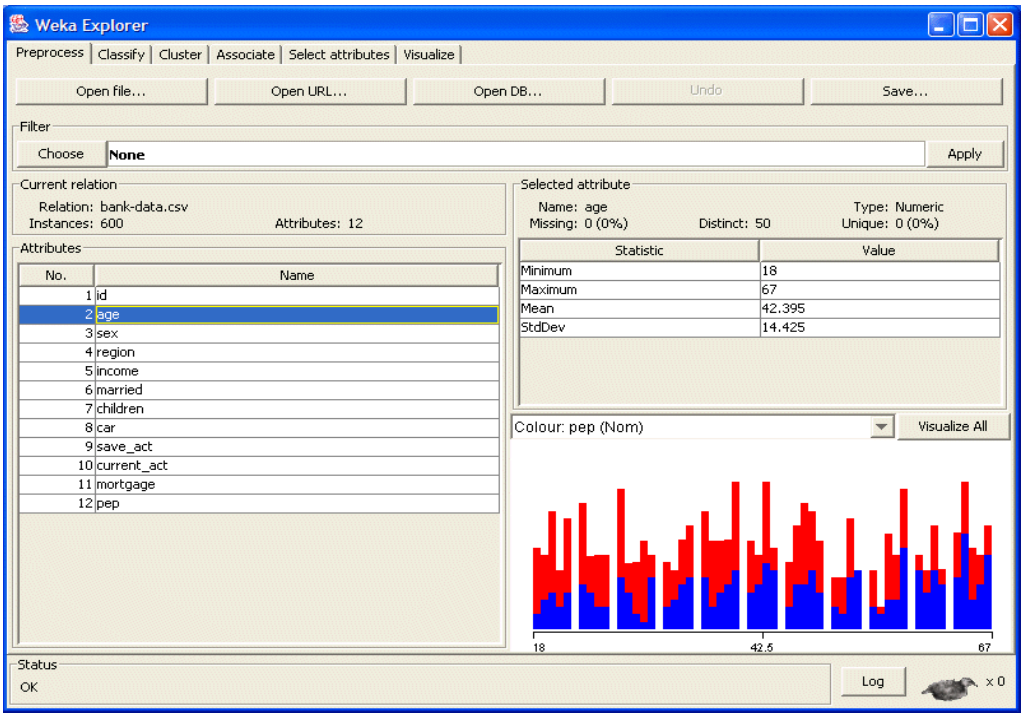

จะเห็นได้ว่าถ้าคลิกดูที่ age (อายุ) จะปรากฏค่า Minmum, Maximum, Mean และ StdDev โดยรวมของข้อมูลคอลัมน์ของอายุ

5. ถ้าเลื่อนลงมาคลิกดูที่ married ก็จะได้ข้อมูลแสดงค่าที่เป็นไปได้สองค่าคือ Yes และ No เครื่องมีจะแสดงเพียงการนับจำนวนที่เป็น Yes และ No เท่านั้น

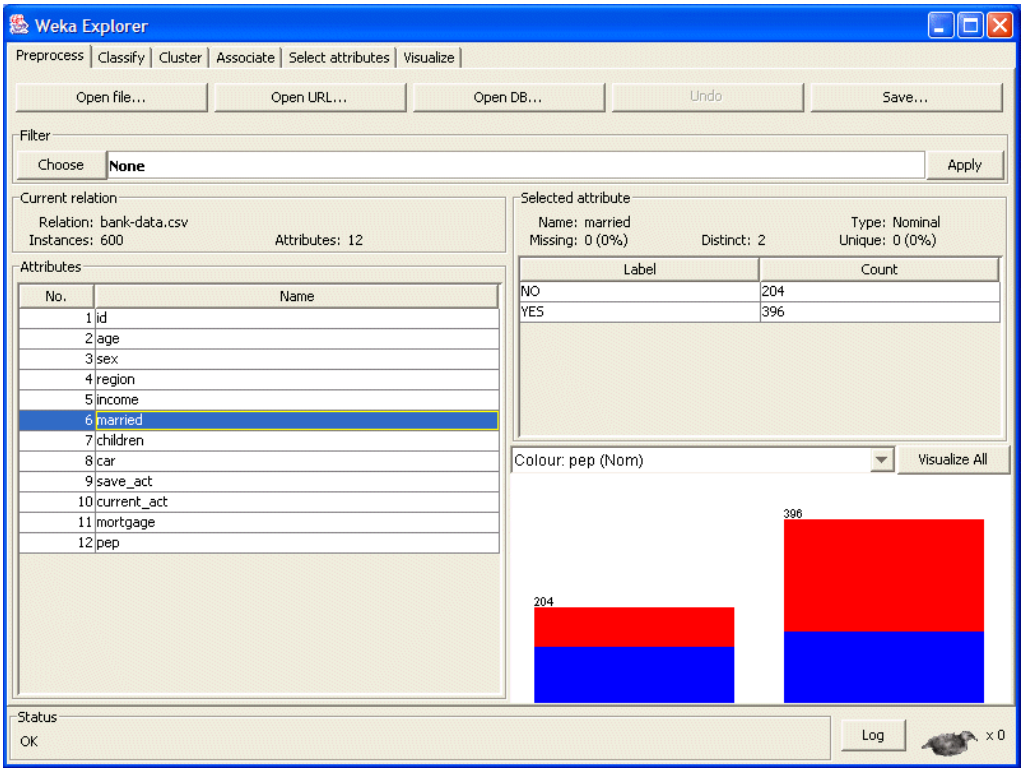

6. ให้กลับมาคลิกที่ข้อมูล id และกดปุ่ม choose ด้านบน Filter และกด +filter และกด + unsupervised และ + attribute และกดเลือก Remove ดังรูป

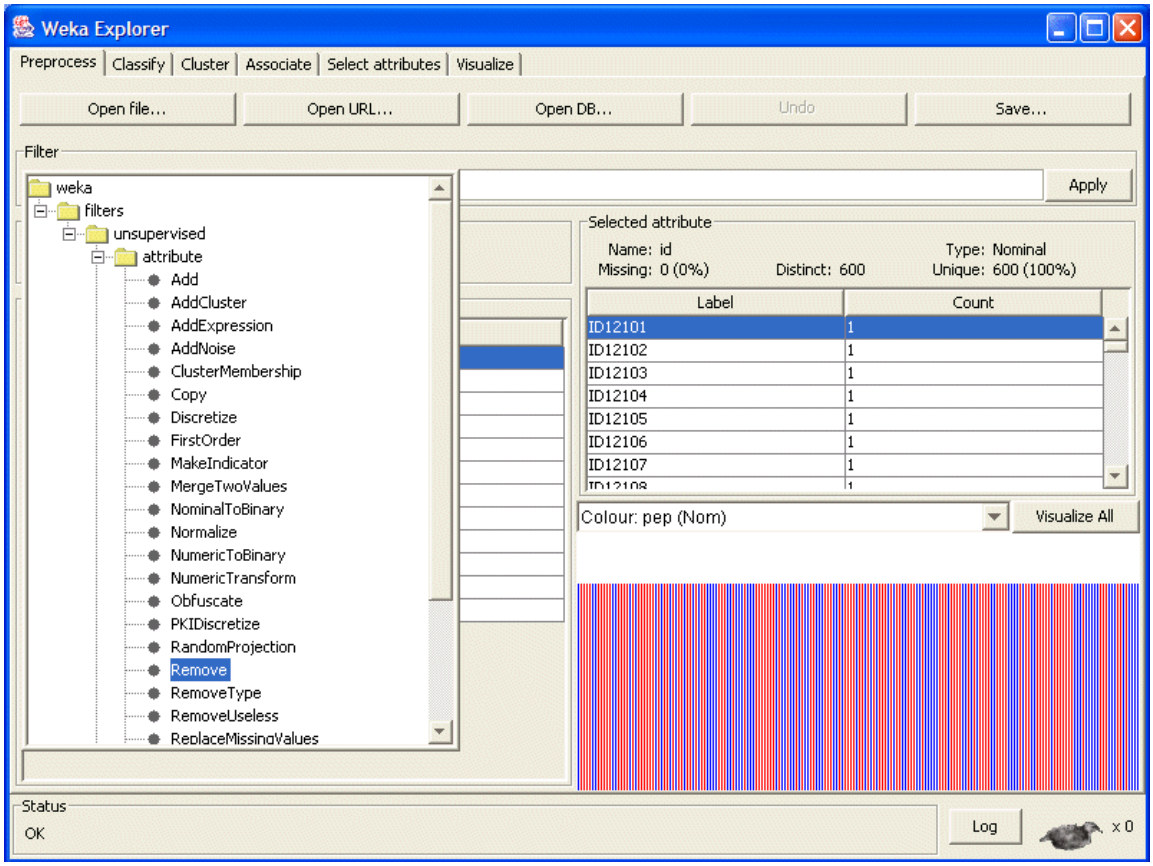

7. หลังจากกดเลือก ให้คลิกคำว่า Remove ข้างปุ่ม Choose จะปรากฏกล่องข้อความ ดังรูป

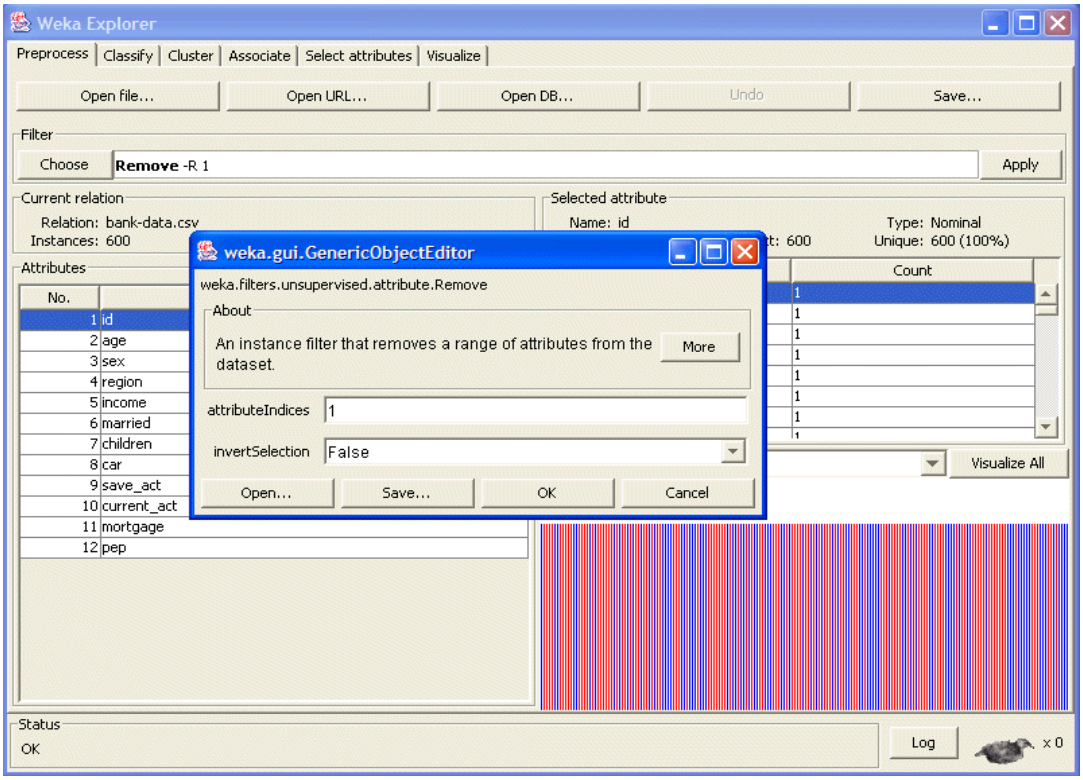

8. หลังจากนั้นให้กรอก attributeIndices เป็น 1 และ invertSelection เป็น False หลังจากนั้นกด OK และกดปุ่ม Apply ด้านขวามือ

9. ให้สังเกตว่าคอลัมน์ id หายไปแล้ว ดังรูป

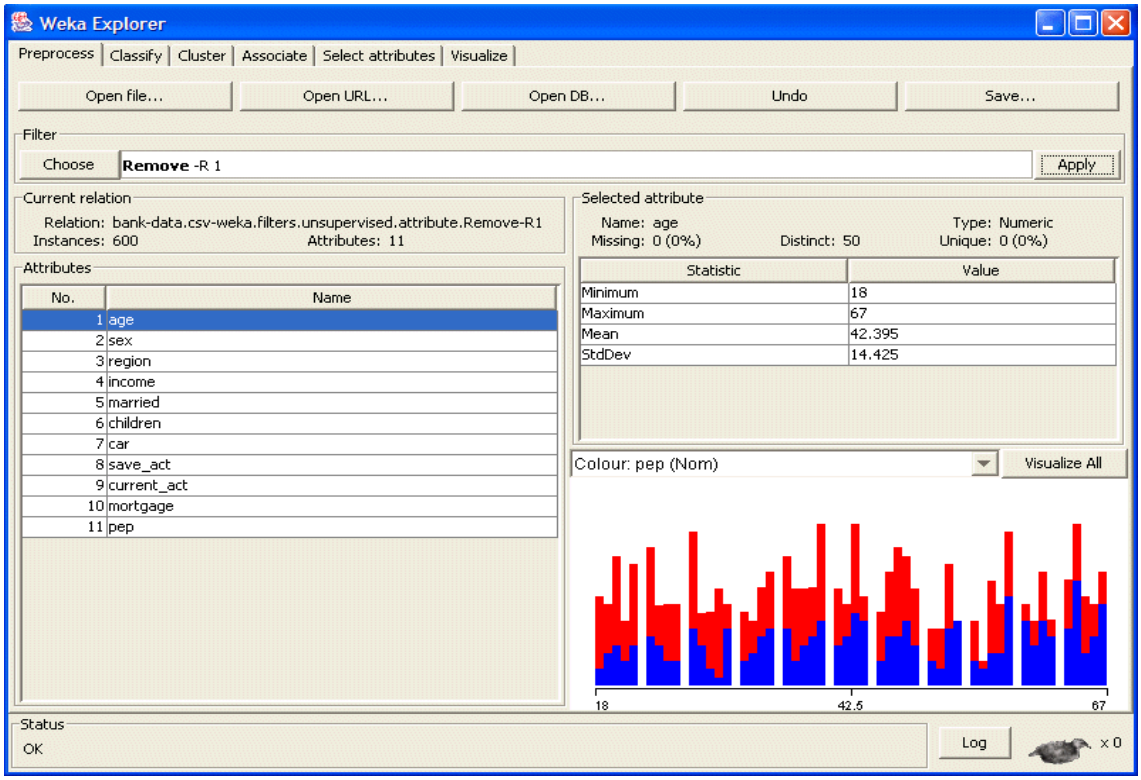

10. หลังจากนั้นให้กด Save...เป็นไฟล์ชื่อ **bank-data-R1.arff** ถ้าเปิดไฟล์ดูก็จะสังเกตว่าข้อมูลเกี่ยวกับ id ก็จะถูกลบออกไปจากไฟล์

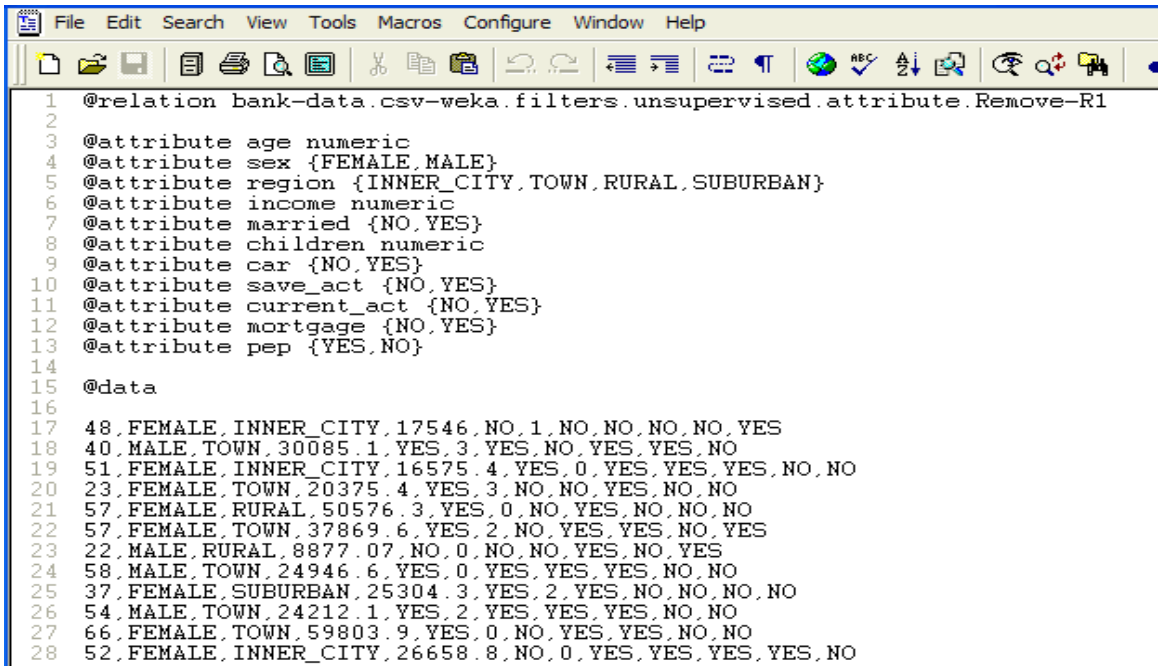

11. ต่อไปให้ลองปรับค่าของ age ตามวิธีของ Binning Method โดยกด choose ด้านบน Filter และกด +filter และกด + unsupervised และ + attribute และกดเลือก Discretize

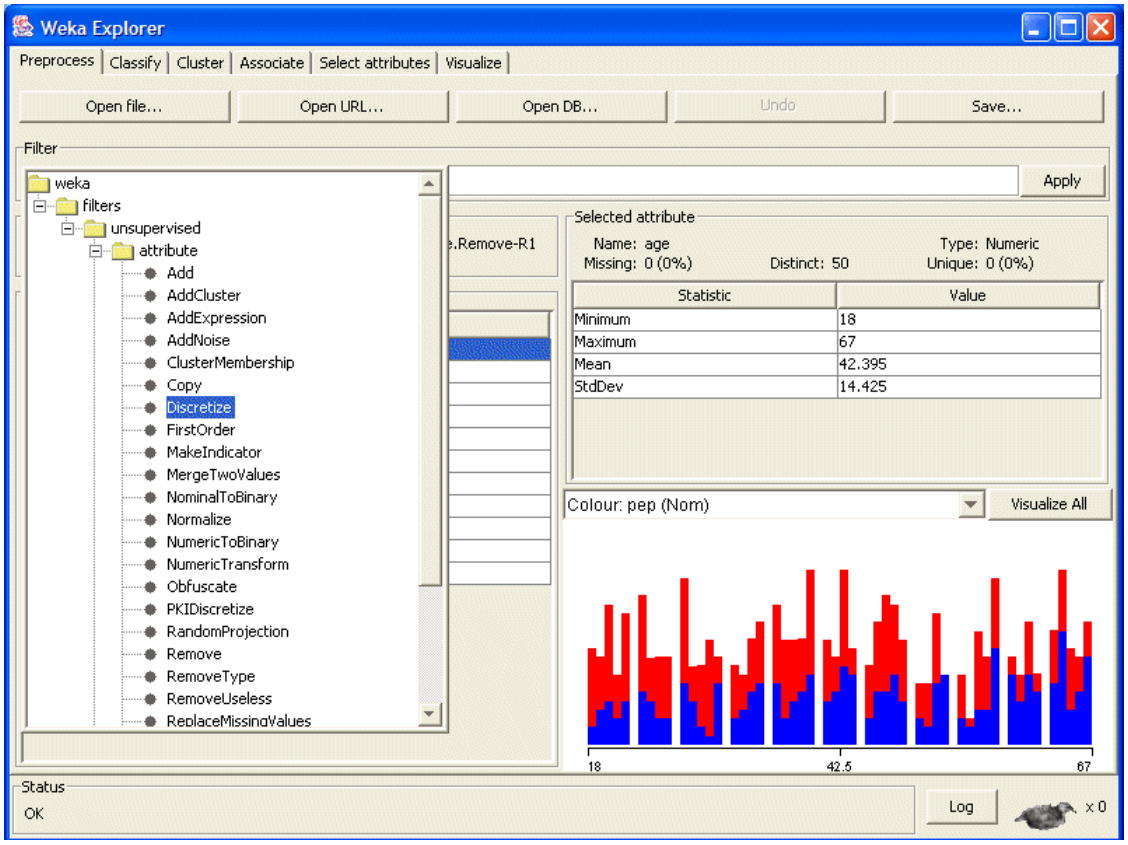

12. หลังจากนั้นให้กดคำว่า Discretize ข้าง choose จะปรากฏกล่องข้อความให้ปรับค่าดังต่อไปนี้

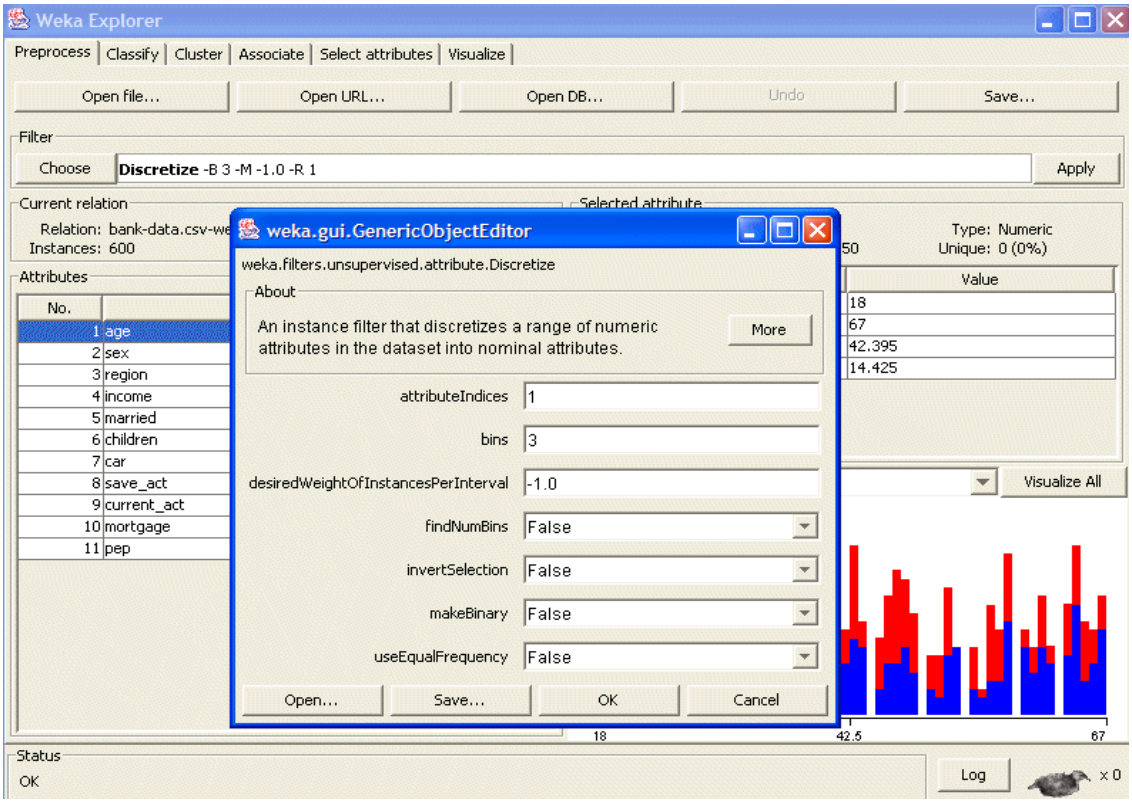

13. จากข้างต้นจะเห็นได้ว่าเป็นวิธี Binning Method โดยที่ปรับค่าของอายุให้เป็นช่วงข้อมูล โดยที่สมมติเราจะแบ่งกลุ่มของอายุเป็น 3 ช่วงดังกล่าว ดังนั้นใส่ค่า bins เท่ากับ 3 เมื่อกดปุ่ม OK และกด apply ข้างขวาสุด ก็จะทำให้ข้อมูลที่จากกระจายตัวมากๆ ทำให้ข้อมูลมีการแบ่งเป็น 3 กลุ่มช่วงอายุเกิดขึ้น

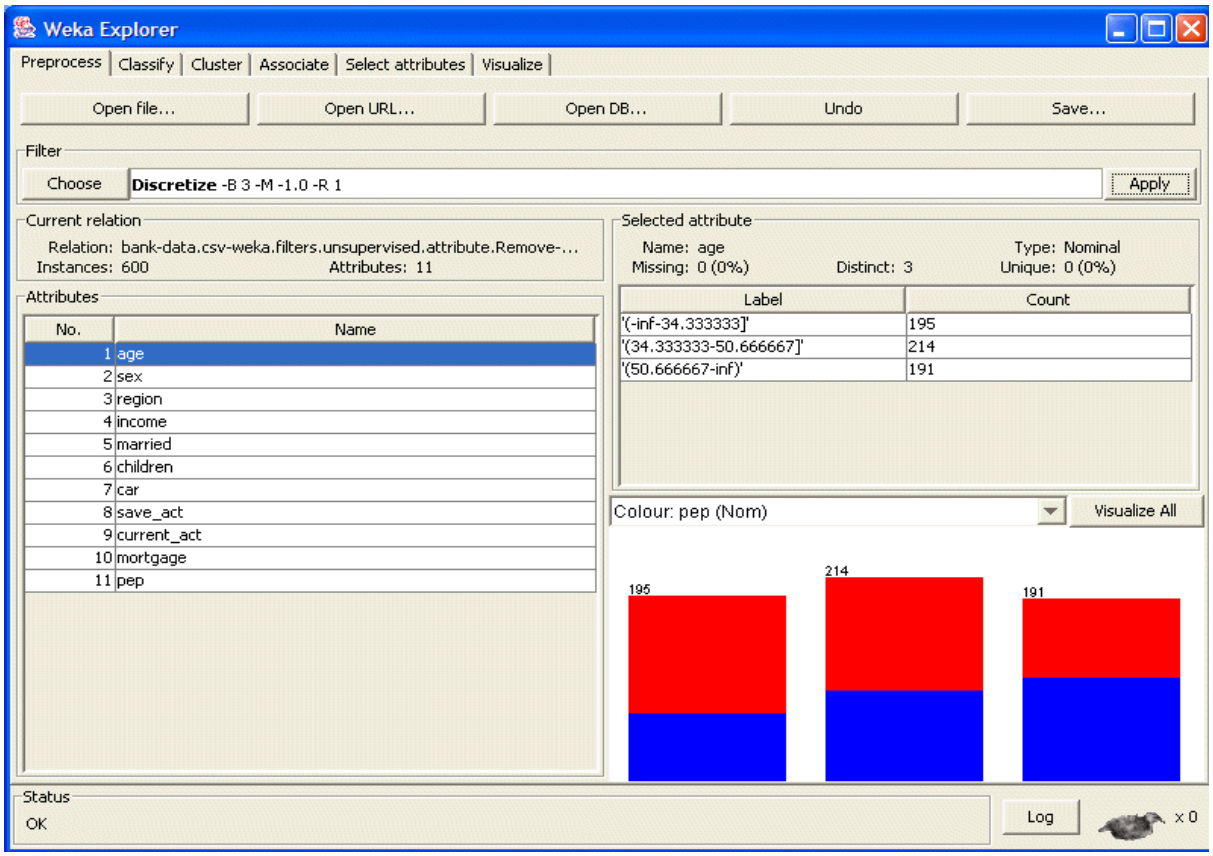

14. ให้กด Save...ปุ่มด้านขวามือ เป็นไฟล์ชื่อ data-bank-R2.arff ถ้าเปิดไฟล์ดูก็จะเห็นการเปลี่ยนแปลงของข้อมูล

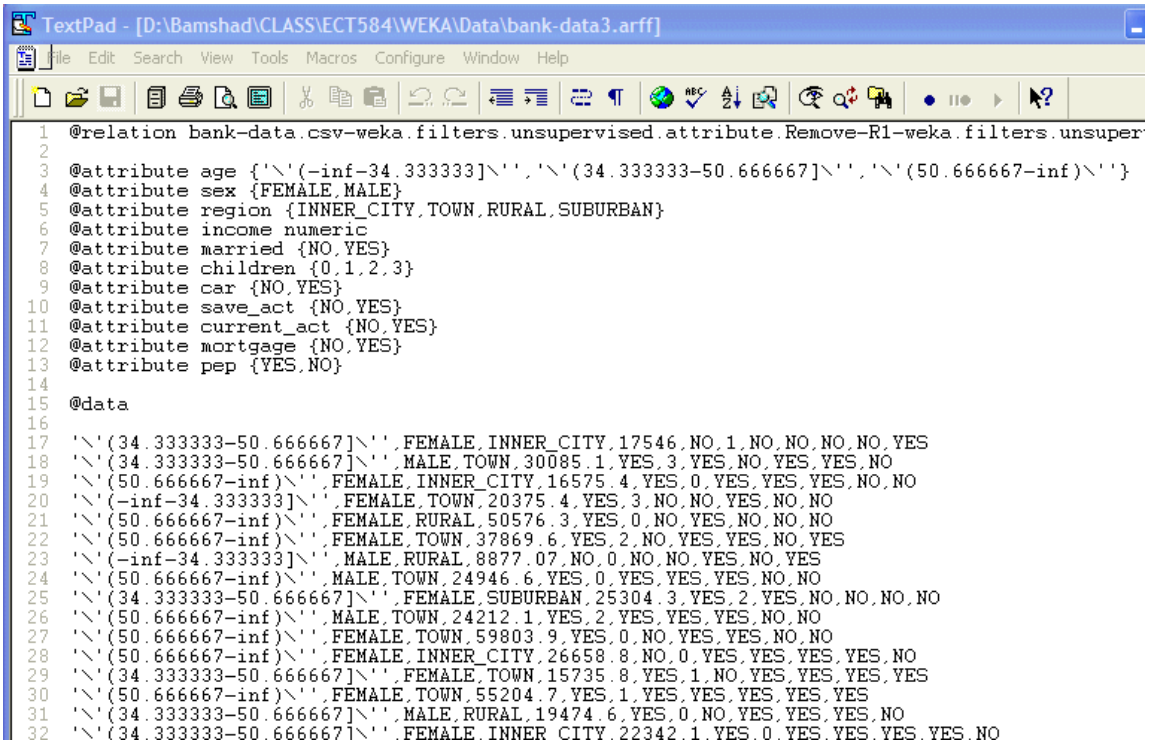


```
@relation bank-data.csv-weka.filters.unsupervised.attribute.Remove-R1-weka.filters.unsuper

@attribute age {'\'(-inf-34.333333]\'','\'(34.333333-50.666667]\'','\'(50.666667-inf)\''}
@attribute sex {FEMALE,MALE}
@attribute region {INNER_CITY,TOWN,RURAL,SUBURBAN}
@attribute income numeric
@attribute married {NO,YES}
@attribute children {0,1,2,3}
@attribute car {NO,YES}
@attribute save_act {NO,YES}
@attribute current_act {NO,YES}
@attribute mortgage {NO,YES}
@attribute pep {YES,NO}

@data

'\'(34.333333-50.666667]\'',FEMALE,INNER_CITY,17546,NO,1,NO,NO,NO,NO,YES
'\'(34.333333-50.666667]\'',MALE,TOWN,30085.1,YES,3,YES,NO,YES,YES,NO
'\'(50.666667-inf)\'',FEMALE,INNER_CITY,16575.4,YES,0,YES,YES,YES,NO,NO
'\'(-inf-34.333333]\'',FEMALE,TOWN,20375.4,YES,3,NO,NO,YES,NO,NO
'\'(50.666667-inf)\'',FEMALE,RURAL,50576.3,YES,0,NO,YES,NO,NO,NO
'\'(50.666667-inf)\'',FEMALE,TOWN,37869.6,YES,2,NO,YES,YES,NO,YES
'\'(-inf-34.333333]\'',MALE,RURAL,8877.07,NO,0,NO,NO,YES,NO,YES
'\'(50.666667-inf)\'',MALE,TOWN,24946.6,YES,0,YES,YES,YES,NO,NO
'\'(34.333333-50.666667]\'',FEMALE,SUBURBAN,25304.3,YES,2,YES,NO,NO,NO,NO
'\'(50.666667-inf)\'',MALE,TOWN,24212.1,YES,2,YES,YES,YES,NO,NO
'\'(50.666667-inf)\'',FEMALE,TOWN,59803.9,YES,0,NO,YES,YES,NO,NO
'\'(50.666667-inf)\'',FEMALE,INNER_CITY,26658.8,NO,0,YES,YES,YES,YES,NO
'\'(34.333333-50.666667]\'',FEMALE,TOWN,15735.8,YES,1,NO,YES,YES,YES,YES
'\'(50.666667-inf)\'',FEMALE,TOWN,55204.7,YES,1,YES,YES,YES,YES,YES
'\'(34.333333-50.666667]\'',MALE,RURAL,19474.6,YES,0,NO,YES,YES,YES,NO
'\'(34.333333-50.666667]\'',FEMALE,INNER_CITY,22342.1,YES,0,YES,YES,YES,YES,NO
```

15. จะเห็นได้ว่าข้อมูลขึ้นเป็น

‘\’(-inf-34.333333) \’’ หมายถึง อายุตั้งแต่ 0-34

‘\’34.333333-50.666667) \’’ หมายถึง อายุตั้งแต่ 34-56

‘\’50.666667-inf \’’ หมายถึง อายุตั้งแต่ 56 -67

แลปปฏิบัติที่ 3 ให้ฝึกปฏิบัติและตอบคำถามต่อดังต่อไปนี้

1. เมื่อ Download ไฟล์ bank-data-missvalue.csv มาไว้ที่เครื่องแล้ว
2. ให้กด Open file และกดดู attribute ทุกอัน ถ้าพบ attribute ใด **<u>มี missing value ให้</u>ใส่ชื่อ attribute และค่า missing value ตรงนี้**

   -Income
3. จากนั้นให้กด choose ด้านบน Filter และกด +filter และกด + unsupervised และ + attribute และกดเลือก ReplaceMissingValues กด OK และ กด Apply
4. กดปุ่ม Save..และบันทึกเป็นชื่อ bank-data-missvalue-R1.csv และกดดูว่า**<u>โปรแกรมแทนค่าที่ขาดหายไปเติมค่าเท่ากับเท่าใด ตอบตรงนี้.....</u>**

   -27470.34

   Original

	A	B	C	D	E	F	G	H	I	J	K	L
1	id	age	sex	region	income	married	children	car	save_act	current_ac	mortgage	pep
2	ID12101	48	FEMALE	INNER_CIT	17546	NO	1	NO	NO	NO	NO	YES
3	ID12102	40	MALE	TOWN	30085.1	YES	3	YES	NO	YES	YES	NO
4	ID12103	51	FEMALE	INNER_CIT	16575.4	YES	0	YES	YES	YES	NO	NO
5	ID12104	23	FEMALE	TOWN	20375.4	YES	3	NO	NO	YES	NO	NO
6	ID12105	57	FEMALE	RURAL	50576.3	YES	0	NO	YES	NO	NO	NO
7	ID12106	57	FEMALE	TOWN	37869.6	YES	2	NO	YES	YES	NO	YES
8	ID12107	22	MALE	RURAL	8877.07	NO	0	NO	NO	YES	NO	YES
9	ID12108	58	MALE	TOWN	24946.6	YES	0	YES	YES	YES	NO	NO
10	ID12109	37	FEMALE	SUBURBAN		YES	2	YES	NO	NO	NO	NO
11	ID12110	54	MALE	TOWN		YES	2	YES	YES	YES	NO	NO
12	ID12111	66	FEMALE	TOWN		YES	0	NO	YES	YES	NO	NO
13	ID12112	52	FEMALE	INNER_CITY		NO	0	YES	YES	YES	YES	NO
14	ID12113	44	FEMALE	TOWN		YES	1	NO	YES	YES	YES	YES
15	ID12114	66	FEMALE	TOWN		YES	1	YES	YES	YES	YES	YES
16	ID12115	36	MALE	RURAL		YES	0	NO	YES	YES	YES	NO
17	ID12116	38	FEMALE	INNER_CITY		YES	0	YES	YES	YES	YES	NO
18	ID12117	37	FEMALE	TOWN		YES	2	NO	NO	NO	YES	NO
19	ID12118	46	FEMALE	SUBURBAN		YES	0	NO	YES	NO	YES	NO
20	ID12119	62	FEMALE	INNER_CITY		YES	0	NO	YES	NO	NO	YES
21	ID12120	31	MALE	TOWN	22522.8	YES	0	YES	YES	YES	NO	NO
22	ID12121	61	MALE	INNER_CIT	57880.7	YES	2	NO	YES	NO	NO	YES
23	ID12122	50	MALE	TOWN	16497.3	YES	2	NO	YES	YES	NO	NO
24	ID12123	54	MALE	INNER_CIT	38446.6	YES	0	NO	YES	YES	NO	NO
25	ID12124	27	FEMALE	TOWN	15538.8	NO	0	YES	YES	YES	YES	NO
26	ID12125	22	MALE	INNER_CIT	12640.3	NO	2	YES	YES	YES	NO	NO
27	ID12126	56	MALE	INNER_CIT	41034	YES	0	YES	YES	YES	YES	NO
28	ID12127	45	MALE	INNER_CIT	20809.7	YES	0	NO	YES	YES	YES	NO
29	ID12128	39	FEMALE	TOWN	20114	YES	1	NO	NO	YES	NO	YES
30	ID12129	39	FEMALE	INNER_CIT	29359.1	NO	3	YES	NO	YES	YES	NO
31	ID12130	61	MALE	RURAL	24270.1	YES	1	NO	NO	YES	NO	YES
32	ID12131	61	FEMALE	RURAL	22042.9	YES	2	NO	YES	YES	NO	NO

ปรับปรุง

	A	B	C	D	E	F	G	H	I	J	K
1	age	sex	region	income	married	children	car	save_act	current_ac	mortgage	pep
2	48	FEMALE	INNER_CIT	17546	NO	1	NO	NO	NO	NO	YES
3	40	MALE	TOWN	30085.1	YES	3	YES	NO	YES	YES	NO
4	51	FEMALE	INNER_CIT	16575.4	YES	0	YES	YES	YES	NO	NO
5	23	FEMALE	TOWN	20375.4	YES	3	NO	NO	YES	NO	NO
6	57	FEMALE	RURAL	50576.3	YES	0	NO	YES	NO	NO	NO
7	57	FEMALE	TOWN	37869.6	YES	2	NO	YES	YES	NO	YES
8	22	MALE	RURAL	8877.07	NO	0	NO	NO	YES	NO	YES
9	58	MALE	TOWN	24946.6	YES	0	YES	YES	YES	NO	NO
10	37	FEMALE	SUBURBAI	27470.34	YES	2	YES	NO	NO	NO	NO
11	54	MALE	TOWN	27470.34	YES	2	YES	YES	YES	NO	NO
12	66	FEMALE	TOWN	27470.34	YES	0	NO	YES	YES	NO	NO
13	52	FEMALE	INNER_CIT	27470.34	NO	0	YES	YES	YES	YES	NO
14	44	FEMALE	TOWN	27470.34	YES	1	NO	YES	YES	YES	YES
15	66	FEMALE	TOWN	27470.34	YES	1	YES	YES	YES	YES	YES
16	36	MALE	RURAL	27470.34	YES	0	NO	YES	YES	YES	NO
17	38	FEMALE	INNER_CIT	27470.34	YES	0	YES	YES	YES	YES	NO
18	37	FEMALE	TOWN	27470.34	YES	2	NO	NO	NO	YES	NO
19	46	FEMALE	SUBURBAI	27470.34	YES	0	NO	YES	NO	YES	NO
20	62	FEMALE	INNER_CIT	27470.34	YES	0	NO	YES	NO	NO	YES
21	31	MALE	TOWN	22522.8	YES	0	YES	YES	YES	NO	NO
22	61	MALE	INNER_CIT	57880.7	YES	2	NO	YES	NO	NO	YES
23	50	MALE	TOWN	16497.3	YES	2	NO	YES	YES	NO	NO
24	54	MALE	INNER_CIT	38446.6	YES	0	NO	YES	YES	NO	NO
25	27	FEMALE	TOWN	15538.8	NO	0	YES	YES	YES	YES	NO
26	22	MALE	INNER_CIT	12640.3	NO	2	YES	YES	YES	NO	NO
27	56	MALE	INNER_CIT	41034	YES	0	YES	YES	YES	YES	NO
28	45	MALE	INNER_CIT	20809.7	YES	0	NO	YES	YES	YES	NO
29	39	FEMALE	TOWN	20114	YES	1	NO	NO	YES	NO	YES
30	39	FEMALE	INNER_CIT	29359.1	NO	3	YES	NO	YES	YES	NO
31	61	MALE	RURAL	24270.1	YES	1	NO	NO	YES	NO	YES
32	61	FEMALE	RURAL	22942.9	YES	2	NO	YES	YES	NO	NO

5. ให้ทำการทดสอบโดยใช้ค่าข้อมูลเข้าไปใช้เทคนิค classify->tree->ID3/J48

ไฟล์	ใช้กับเทคนิค ID3 (ได้หรือไม่ได้)	ใช้กับ J48 (ได้หรือไม่ได้)	Naivebayes(ได้หรือไม่ได้)	Apriori (ได้หรือไม่ได้)	วิเคราะห์เหตุผล
bank-data-missvalue.csv	**Correctly: 90.3333%**	**Correctly:** 90.3333%	**Correctly:** 64.1667%	**ใช้ไม่ได้**	Dataset Bank-data-missvalue.csv เหมาะสมกับเทคนิค J48 ด้วยค่าความถูกต้อง 90.3333%
bank-data-missvalue-R1.csv (removeid+replace)	**Correctly:** 89.8333%	**Correctly:** 89.8333%	**Correctly:** 65%	**ใช้ไม่ได้**	Dataset Bank-data-missvalue-R1.csv เหมาะสมกับเทคนิค J48 ด้วยค่าความถูกต้อง 89.8333%
bank-data-missvalue-R2.csv(Replace+Bining3)	Correctly: 89.6667%	**Correctly:** 89.6667%	**Correctly:** 64.3333%	**ใช้ไม่ได้**	Dataset Bank-data-missvalue-R2.csv เหมาะสมกับเทคนิค J48 ด้วยค่าความถูกต้อง 89.6667%

6. ให้ลองจัดกลุ่มข้อมูลโดยวิธี Binning Method ของไฟล์ bank-data-missvalue-R1.csv โดยลองแบ่ง 3,4,5 แล้ววิเคราะห์ว่ามีผลต่อความถูกต้องโดยใช้วิธี ID3 และ J48 หรือไม่

N of Binning Method	%ความถูกต้องเทคนิค ID3	%ความถูกต้องเทคนิค J48	%ความถูกต้องเทคนิค Naivebayes
3	Correctly: 89.6667%	Correctly: 89.6667%	Correctly: 64.3333%
4	Correctly: 90.3333%	Correctly: 90.3333%	Correctly: 63.6667%
5	Correctly: 90.3333%	Correctly: 90.3333%	Correctly: 64.6667%

จงสรุป ความรู้ เนื้อหา ที่ได้จากการทำแลปนี้ 5-10 บรรทัด หรือจะวาดรูปประกอบก็ได้ ทำตรงนี้

จากการปฏิบัติการทำให้เข้าใจกระบวนการ Data Preprocessing (การเตรียมข้อมูล) ด้วยโปรแกรม Weka ซึ่งเป็นขั้นตอนสำคัญก่อนนำเข้าโมเดล โดยได้เรียนรู้ 3 เทคนิคหลัก คือ

1. Data Cleaning: การจัดการค่าสูญหาย (Missing Value) โดยแทนที่ด้วยค่าเฉลี่ย

2. Feature Selection: การตัด Attribute ที่ไม่จำเป็นออก (Remove ID)

3. Discretization: การทำ Binning เพื่อแปลงข้อมูลตัวเลขต่อเนื่องให้เป็นช่วงข้อมูล (Categories)

ซึ่งจากการทดลองพบว่าการเลือกจำนวน Bin และวิธีการ Preprocessing ที่ต่างกัน ส่งผลต่อความแม่นยำ (Accuracy) ของโมเดล โดยในชุดข้อมูลนี้เทคนิค Decision Tree (J48, ID3) ให้ผลลัพธ์ดีกว่า NaiveBayes

***ขั้นตอนการส่งแลปปฏิบัติการ ให้ดำเนินการดังนี้

1. เปลี่ยนชื่อไฟล์เป็นรหัสนักศึกษาแบบมีขีด
2. บันทึกไฟล์และจัดส่งใน assignment ชื่อ Lab Preprocessing data
3. เมื่อตรวจสอบความเรียบร้อยแล้ว สามารถออกจากระบบได้